

Nghiên cứu sâu pipeline End-to-End cho AIC 2026: Textual KIS, Q&A và TRAKE

Kết luận chính

Tôi đã đọc tài liệu “**Thông tin vòng Sơ tuyển AIC2026.pdf**”, kiểm tra ba ảnh mô tả pipeline của bạn, đọc toàn bộ notebook `AIC-2026-Baseline-v1.ipynb`, đồng thời đối chiếu với các hệ thống AIC 2024–2025 và các nghiên cứu temporal grounding mới tới tháng 8/2026.

Kết luận quan trọng nhất: pipeline trong ba ảnh của bạn **đúng hướng về mặt kiến trúc retrieval → fusion → task-specific reasoning → ranking**, đặc biệt phần TRAKE dùng **event-wise similarity + Dynamic Programming bảo toàn thứ tự thời gian** rất sát với cách DANTE giải quyết TRAKE tại AIC 2025. Query rewriting/query expansion cũng đã được các đội AIC trước chứng minh là hữu ích. ¹

Tuy nhiên, tôi **không khuyến nghị triển khai nguyên trạng pipeline hiện tại để submit**. Có một vấn đề có thể làm mất điểm rất nặng:

Bạn đang coi keyframe retrieval gần như là điểm cuối của localization, trong khi BTC chấm bằng `frame_id` trên video thật, và riêng TRAKE khoảng GT thường dưới 10 frame.

Tài liệu BTC nói rõ keyframe chỉ là dữ liệu hỗ trợ, tên `0000.jpg`, `0001.jpg`, ... chỉ thể hiện **thứ tự keyframe**; frame index thật tương ứng nằm trong metadata. Đồng thời, **Video mới là dữ liệu thi chính thức**, còn Keyframes, Objects, CLIP features và Metadata chỉ là dữ liệu hỗ trợ. Vì thế thiết kế tốt nhất là:

Coarse Retrieval trên keyframe → chọn video / vùng thời gian → Dense Refinement trên VIDEO GỐC → ori

Điểm này càng quan trọng vì các nghiên cứu mới về temporal grounding cho thấy **short moments** và việc giữ độ phân giải thời gian cao vẫn là điểm yếu lớn: MomentMix/Length-Aware DETR nhắm trực tiếp vào short-moment localization; HieraMamba nhấn mạnh việc không đánh mất fine-grained temporal detail; ResidualViT được thiết kế cho temporally dense frame features; các hệ thống mới như LensWalk thậm chí chủ động thay đổi mật độ sampling khi cần quan sát kỹ hơn. ²

Vấn đề lớn thứ hai là pipeline của bạn hiện **quá thiên về CLIP visual similarity**. Với dữ liệu kiểu AIC, nên có tối thiểu bốn nguồn bằng chứng:

Visual + OCR + ASR/Transcript + Caption/Temporal context.

Đây không chỉ là đề xuất lý thuyết. Các hệ thống AIC gần nhất đã đi đúng hướng này: MERVIN kết hợp keyframe, transcript và video summary; AIO-Owlgorithms kết hợp semantic retrieval và OCR; U-CESE bổ sung caption theo thời gian. ³

Còn notebook baseline thì câu trả lời rất rõ:

Notebook không phải một end-to-end baseline cho ba task. Nó chủ yếu là tutorial để import keyframe vào FiftyOne, gán object detection, nạp CLIP ViT-B/32 feature do BTC cung cấp, tạo similarity index và dùng FiftyOne để search/filter/visualize.

Nó **không thay đổi logic kiến trúc bạn đề xuất**. Bạn hoàn toàn có thể thay FiftyOne bằng FAISS/Milvus/Numpy mà logic retrieval vẫn giữ nguyên. Nhưng có một cái bẫy cực quan trọng trong notebook: `sample["frameid"]` được lấy từ **tên file keyframe**, không phải original video frame index. Nếu lấy trường này để submit trực tiếp thì có nguy cơ sai hoàn toàn.

Đọc yêu cầu sơ tuyển và những hệ quả đối với thiết kế

Textual KIS thực chất cần tối ưu gì

Theo tài liệu BTC, Textual KIS cho một mô tả sự kiện bằng ngôn ngữ tự nhiên và yêu cầu:

`<video_id>, <frame_id>`

Câu trả lời đúng khi đồng thời:

$$video_id = GT_v$$

và

$$frame_id \in [s, e].$$

Điều này tạo ra một đặc điểm rất có lợi: **bạn không cần tìm đúng một “canonical frame” duy nhất; chỉ cần một frame bất kỳ nằm trong interval đúng**. (Nguồn: *Thông tin vòng Sơ tuyển AIC2026.pdf*, mục 1.1 và 2.1.1.)

Vì vậy KIS nên được nhìn thành hai tầng:

Video/Event retrieval $\rightarrow$ frame localization trong event.

CLIP keyframe rất phù hợp với tầng đầu, nhưng không nhất thiết đủ tốt cho tầng thứ hai.

Q&A khó hơn KIS ở chỗ localization và answering bị ràng buộc cùng lúc

Định dạng là:

`<video_id>, <frame_id>, <answer>`

BTC chỉ cho điểm khi **cả ba** cùng đúng:

$$v_i = GT_v, \quad id_i \in [s, e], \quad a_i = GT_a.$$

Do đó pipeline:

```
retrieval
→ chọn 1 evidence keyframe
→ VQA
```

như trong ảnh của bạn có thể chạy được ở baseline, nhưng khá mong manh.

Một câu hỏi chẳng hạn:

“Trong lúc người đàn ông đưa tài liệu cho người phụ nữ, trên màn hình phía sau ghi tên tổ chức nào?”

có thể cần đồng thời:

- một vài frame trước/sau để xác định đúng sự kiện,
- frame rõ chữ để OCR,
- transcript nếu thông tin được nói chứ không hiện trên hình,
- VLM để suy luận câu trả lời.

Nghiên cứu TOGA tại ICCV 2025 cũng đi theo hướng **answering và temporal grounding gắn với nhau**, thay vì coi localization và QA là hai bài toán hoàn toàn độc lập; tác giả báo cáo rằng joint answer-grounding cải thiện cả QA lẫn grounding. ⁴

TRAKE mới là nơi pipeline phải thiết kế lại kỹ nhất

TRAKE yêu cầu tìm **một video duy nhất**, sau đó trả về một frame cho từng event:

```
<video_id>, <frame_id_1>, ..., <frame_id_N>
```

Nếu video sai:

$$R = 0.$$

Nếu video đúng:

$$R = \frac{1}{N} \sum_{j=1}^N I(id_j \in [s_j, e_j]).$$

Điểm cực kỳ quan trọng trong tài liệu là khoảng semantic keyframe **“thông thường là dưới 10 frame”**. (Nguồn: *Thông tin vòng Sơ tuyển AIC2026.pdf*, mục 2.1.3.)

Ví dụ một video 25 fps thì 10 frame chỉ khoảng:

$$10/25 = 0.4 \text{ s.}$$

Nếu keyframe của bạn nằm cách thời điểm GT vài giây thì semantic retrieval có thể nói rằng bạn tìm **đúng sự kiện**, nhưng evaluator vẫn cho event đó **0 điểm**.

Đây là lý do tôi coi bước **dense local refinement từ video thật** là thay đổi bắt buộc, không phải một optimization nhỏ.

Metric làm thay đổi chiến lược Top-100

BTC cho phép tối đa 100 answers và tính:

$$R@k = \max_{1 \leq i \leq k} R(r_i)$$

với:

$$k \in \{1, 5, 20, 50, 100\}.$$

Sau đó:

$$FinalScore = \frac{R@1 + R@5 + R@20 + R@50 + R@100}{5}.$$

(Nguồn: *Thông tin vòng Sơ tuyển AIC2026.pdf*, mục 2.2.)

Đây là một chi tiết **cực kỳ đáng khai thác**.

Metric không yêu cầu mọi prediction trong Top-100 đều đúng. Nó yêu cầu:

1. phương án tốt nhất phải lên càng cao càng tốt;
2. phía sau có thể chứa những giả thuyết thay thế để hedge uncertainty.

Ví dụ với TRAKE, nếu event thứ ba có hai peak gần ngang nhau, thay vì chỉ giữ:

V1, f1, f2, f3a, f4

bạn nên có thêm:

V1, f1, f2, f3b, f4

ở rank sau.


Đây chính là lý do tôi không nghĩ thiết kế cố định:

Top-20 paths/video × 5 videos

là tối ưu. Nó là **baseline hợp lý**, nhưng allocation Top-100 nên phụ thuộc confidence.

Đánh giá chi tiết sơ đồ end-to-end bạn gửi

Sơ đồ của bạn hiện là:



Phần Rewrite và Planner: nên giữ

Bạn đang giữ cả:

```
raw_query
rewritten_query
```

Đây là quyết định đúng.

Không nên overwrite raw query vì rewrite bằng LLM có thể:

- bỏ mất tên riêng;
- biến một thuộc tính chính xác thành từ gần nghĩa nhưng visual encoder hiểu khác;
- “làm giàu” thêm chi tiết vốn không có trong truy vấn.

RAPID cũng dùng LLM để semantic correction/enrichment và parallel retrieval, nhưng có bước đánh giá kết quả trở lại theo **original query** thay vì tin tuyệt đối vào augmented query. ⁵

ED-VTG cũng đưa ra một kết quả rất phù hợp với vấn đề của bạn: họ enrich câu query trước khi grounding, nhưng phải có cơ chế chọn giữa các query representations để giảm noise và hallucination từ enrichment. ⁶

Vì vậy tôi sẽ sửa thành:

```
raw_vi
├─ normalized_vi
├─ literal_en
├─ visual_en
├─ entities[]
├─ OCR_terms[]
```

```
| speech_terms[]  
| events[]  
| constraints[]
```

thay vì chỉ có:

anchor + 10 generic expansions.

Một ví dụ:

“Người dẫn chương trình đứng trước bảng có chữ VINFAST rồi một chiếc xe màu đỏ chạy vào sân khấu.”

Planner nên sinh:

```
{  
  "visual_global": "a presenter standing on a stage as a red car enters",  
  "visual_objects": [  
    "presenter on stage",  
    "red car entering a stage"  
  ],  
  "ocr_terms": ["VINFAST"],  
  "entities": ["VINFAST"],  
  "temporal_events": [  
    "presenter standing in front of a sign",  
    "red car enters the stage"  
  ]  
}
```

chứ không chỉ sinh 10 paraphrase gần giống nhau.

“10 expansion → chọn 2” không sai, nhưng đang hơi cứng

Ý tưởng dùng diversity selector kiểu MMR là hợp lý: bạn muốn các query vừa gần query gốc vừa không hoàn toàn trùng nhau.

Nhưng **chọn cố định đúng hai query** chỉ là heuristic.

Có query chỉ cần một representation:

“một chiếc xe buýt màu xanh”

nhưng query khác có rất nhiều channel:

“Phóng viên đứng trước bảng chữ VinFast, sau đó CEO nói về doanh số và biểu đồ 2025 hiện trên màn hình.”

Query sau có ít nhất:

- visual appearance,
- OCR,
- named entity,
- spoken content,
- temporal event.

Hai paraphrase CLIP không thể thay thế các modality đó.

Tôi đề xuất thay:

```
10 expansions
→ MMR
→ 2 expansions
```

bằng:

```
Query Planner
↓
3-6 role-specific retrieval branches
```

và **branch nào không phù hợp thì weight ≈ 0 .**

English anchor là hợp lý cho CLIP baseline, nhưng không nên loại tiếng Việt

BTC cho sẵn feature từ **CLIP ViT-B/32**. Vì vậy khi so text với `.npy` do BTC cung cấp, bạn phải dùng text embedding thuộc **đúng joint embedding space tương ứng**.

Notebook BTC làm đúng điều đó khi tạo index bằng:

```
fob.compute_similarity(
    dataset,
    model="clip-vit-base32-torch",
    embeddings=clip_embeddings,
    brain_key="img_sim",
)
```

FiftyOne hiện hỗ trợ việc tạo similarity index từ precomputed embeddings và lưu model tương ứng để thực hiện text-prompt similarity search; model `clip-vit-base32-torch` là CLIP ViT-B/32 hỗ trợ joint image/text embeddings. ⁷

Do đó:

```
CLIP-B/32 text
↔ CLIP-B/32 image features
```

là đúng.

Nhưng:

```
SigLIP2 text embedding
↔ CLIP-B/32 image .npy
```

là **sai**, dù cùng có 512/768 dimension đi nữa. Hai vector space không được jointly aligned.

Nếu bạn muốn dùng SigLIP2, Perception Encoder hoặc một video encoder mạnh hơn, hãy tạo **index thứ hai**:

```
Index A:
BTC CLIP-B/32 image
↔ CLIP-B/32 text

Index B:
recomputed SigLIP2 image
↔ SigLIP2 text
```

rồi fuse ranking.

SigLIP2 là lựa chọn đáng thử vì model được thiết kế multilingual và cải thiện image-text retrieval/localization so với thế hệ trước. Perception Encoder cũng được báo cáo mạnh trên image/video retrieval, và đáng chú ý chính MERVIN đã dùng Perception Encoder cho AIC 2025. ⁸

Weighted RRF: giữ được

Phần:

```
anchor retrieval
expansion 1 retrieval
expansion 2 retrieval
      ↓
union
      ↓
Weighted RRF
```

tôi đánh giá là tốt cho phiên bản đầu.

Ưu điểm của rank fusion là không phải giả định cosine scores từ nhiều query/modality đã được calibrate giống nhau.

Có thể dùng:

$$RRF(d) = \sum_q \frac{w_q}{C + \text{rank}_q(d)}$$

với ví dụ:

raw/original query	w = 1.0
anchor	w = 1.0
visual expansion	w = 0.8
context expansion	w = 0.6

Quan trọng hơn: **raw/original query phải luôn có một đường retrieval hoặc reranking riêng**. Đừng để LLM expansions có quyền hoàn toàn thay thế query gốc. Đây cũng phù hợp với thiết kế RAPID. ⁵

Khi có OCR, ASR, caption, tôi vẫn có thể dùng RRF để fusion:

$$\text{score} = RRF_{\text{visual}} + RRF_{\text{OCR}} + RRF_{\text{ASR}} + RRF_{\text{caption}}.$$

Sau này khi bạn có validation labels đủ tốt, có thể học weights hoặc calibration.

Textual KIS: thiếu bước fine localization

Ảnh của bạn đang kết thúc:

```
Top-N keyframes
→ union
→ RRF
→ Top-100 <video_id, frame_id>
```

Tôi sẽ thay bằng:

```
Top-N keyframes
↓
RRF
↓
Top candidate regions
↓
LOAD ORIGINAL VIDEO
↓
dense local scan around each region
↓
best ORIGINAL frame
↓
Top-100
```

Ví dụ keyframe candidate tương ứng original frame 12,500.

Không submit ngay 12,500.

Hãy scan:

12000 ... 13000

hoặc trước hết:

2-5 fps

để xác định sub-region, sau đó:

every frame

trong ± 0.5 –1 giây quanh peak.

Đây là mô hình coarse-to-fine rất phù hợp với việc video dài nhưng GT ngắn. Nghiên cứu hiện tại cũng đang hướng mạnh tới việc bảo toàn temporal resolution, đặc biệt HieraMamba cho long-video grounding, MomentMix cho short moments, và ResidualViT cho dense frame-level feature computation.

9

Q&A: “một evidence keyframe” là điểm yếu

Hiện tại:

retrieval
→ evidence keyframe
→ VQA/VLM

Tôi đề xuất:

retrieval
↓
candidate temporal region
↓
short clip + dense frames
↓
OCR + ASR + VLM
↓
answer + support interval
↓
frame refinement

Ví dụ:

candidate timestamp: 04:31
evidence window: 04:26 - 04:36

Trong window này có thể lấy:

- 8–16 frames cho VLM;
- OCR của các frame rõ chữ;
- ASR từ 04:24–04:38;
- caption/context của shot trước và shot sau.

VLM nên được prompt để trả về structured output kiểu:

```
{  
  "answer": "5",  
  "support_start": 271.4,  
  "support_end": 273.0,  
  "confidence": 0.88  
}
```

sau đó mới chọn original frame bên trong support interval.

Đây là biến thể thực dụng của tư tưởng temporally grounded QA trong TOGA. ⁴

TRAKE: phần DP của bạn rất đúng hướng

Đây là phần tôi thích nhất trong sơ đồ.

Bạn viết:

```
mỗi video:  
  encode từng event  
  so khớp event với frame features  
  ↓  
  Top-M Path DP ép frame tăng dần
```

Điều này gần như cùng abstraction với DANTE của AIO-Owlgorithms tại AIC 2025.

DANTE xây dựng:

$$S[i, t] = \cos(u_i, E[t])$$

với event i và keyframe t , rồi:

$$DP[i, t] = S[i, t] + \max_{\tau < t} (DP[i - 1, \tau] - \lambda(t - \tau)).$$

Do đó thứ tự event được đảm bảo trong khi vẫn cho phép khoảng thời gian giữa các event linh hoạt. Họ còn tối ưu recurrence xuống $O(NT)$. ¹⁰

Vì thế:

Không cần bỏ DP của bạn. Hãy phát triển nó thành trung tâm của TRAKE head.

Nhưng tôi sẽ thay ba điểm.

Đầu tiên, **Top-5 videos không nên chỉ được chọn bằng "context retrieval từ 3 query"**.

Một video có thể rất giống query toàn cục nhưng thiếu event thứ ba. Tôi đề xuất:

$$VideoScore(v) = \alpha G(v) + \beta C(v) + \gamma P(v),$$

trong đó:

$G(v)$ = global retrieval score,

$$C(v) = \frac{1}{N} \sum_{j=1}^N \max_t S_v[j, t],$$

là **event coverage**, còn

$P(v)$ = best monotonic path score.

Như vậy video phải vừa:

- đúng bối cảnh;
- có evidence cho từng event;
- có các event theo thứ tự hợp lý.

Thứ hai, DP phải chạy trên candidate sequence đủ dày. DANTE AIC 2025 vận hành trên keyframe sequence và rất phù hợp cho retrieval/alignment coarse; nhưng với AIC 2026 BTC nói interval thường <10 frame, tôi sẽ thêm bước:

```
DP coarse keyframes
  ↓
(t1, t2, ..., tn)
  ↓
dense local scan on original video
  ↓
(t1*, t2*, ..., tn*)
```

Thứ ba, **không chỉ giữ best path**.

Hãy giữ K-best monotonic paths.

Ví dụ:

Path A: 320, 625, 1040, 1422
Path B: 320, 625, 1045, 1422
Path C: 321, 625, 1040, 1422

Nếu event 3 chưa chắc chắn, các alternative paths rất có giá trị do evaluator sử dụng `max R-score` trong Top-k.

Top-20 path × 5 videos: nên đổi thành dynamic budget

Thay:

$$20 \times 5 = 100$$

một cách cứng nhắc, tôi sẽ phân phối kiểu:

Rank 1:
best path of best video

Rank 2-5:
high-confidence alternatives,
mostly top 2-3 videos

Rank 6-20:
K-best path variants,
slightly different boundaries

Rank 21-50:
broader video hypotheses

Rank 51-100:
dense refinement / low-confidence alternatives

Nếu video 1 có posterior 0.78 và video 5 chỉ 0.02 thì dành 20 slot cho video 5 là lãng phí.

Ngược lại, nếu:

V1 = 0.31
V2 = 0.29
V3 = 0.25

thì nên diversify mạnh giữa ba video.

Các paper và hệ thống sát bài toán nhất hiện nay

Không phải paper nào về “video grounding” cũng đáng đưa vào AIC. Tôi chia chúng theo mức độ hữu dụng thực tế.

Công trình	Mức liên quan với AIC 2026	Ý tưởng nên lấy
Integrated Semantic and Temporal Alignment / DANTE + QUEST	★★★★★	Query rewrite, OCR, semantic retrieval, ordered-event DP
MERVIN	★★★★★	Visual + transcript + summaries, Perception Encoder
U-CESE	★★★★★	Clip-level retrieval, temporal captions/ ReCap
RAPID	★★★★★	LLM query enrichment + parallel retrieval + original-query verification
ED-VTG, ICCV 2025	★★★★☆	Enrich query nhưng kiểm soát hallucination; fine temporal grounding
TOGA, ICCV 2025	★★★★☆	Joint temporal grounding + QA
MomentMix + Length-Aware DETR, WACV 2026	★★★★☆	Short-moment localization
HieraMamba, CVPR 2026	★★★★☆	Preserve fine temporal detail trong video dài
ResidualViT, ICCV 2025	★★★★☆	Dense frame features với chi phí thấp hơn
TimeLens2, 2026	★★★☆☆	Generalist MLLM temporal grounding, variable-cardinality evidence intervals
TimePLE, 2026	★★★☆☆	Interval-native temporal representation, đặc biệt cải thiện short-duration events
LensWalk, CVPR 2026	★★★☆☆	Coarse-to-fine/adaptive frame observation

Nhóm AIC-specific là quan trọng nhất

DANTE/QUEST là paper gần pipeline của bạn nhất. Hệ thống của họ dùng scene segmentation, visual embedding, OCR, LLM rewriting; riêng DANTE xây dựng similarity matrix giữa từng event và keyframe rồi dùng DP để tìm narrative-order path. Đây gần như là bằng chứng trực tiếp rằng TRAKE branch của bạn đang đi đúng abstraction. ¹⁰

Một điểm khác rất đáng học từ paper này là họ không coi semantic embedding là tất cả: **OCR Search là một retrieval mode độc lập**, và metadata/keyframe ID được thiết kế thành canonical join key giữa nhiều backend. ¹⁰

MERVIN có ý nghĩa đặc biệt vì bài toán là Vietnamese news-video retrieval và hệ thống được dùng tại AIC HCMC 2025. Họ tích hợp keyframes, transcripts và summaries; dùng Perception Encoder cho visual representation và textual embedding riêng cho tiếng Việt, rồi index bằng Milvus. Tác giả báo cáo 79/88 điểm ở qualification 2025. ¹¹

Điểm tôi rút ra không phải là “copy MERVIN”, mà là:

AIC retrieval không nên chỉ là CLIP image-text retrieval

U-CESE bổ sung một hướng nữa: ReCap tạo caption có temporal consistency thay vì caption từng frame hoàn toàn độc lập. Điều này đặc biệt hữu ích khi query mô tả “sau đó”, “tiếp theo”, “trước khi”, tức đúng pattern của TRAKE. ¹²

RAPID là bằng chứng tốt cho query expansion của bạn. Họ semantic-correct/enrich query bằng LLM, chạy parallel retrieval rồi đánh giá relevance trở lại so với original query. Do đó pipeline của bạn nên giữ `raw_query` không chỉ để log mà phải thực sự dùng nó cho retrieval/reranking. ⁵

Một hệ thống AIC 2025 khác cũng báo cáo kết hợp **query expansion với cross-modal temporal event retrieval**, cho phép các scene khác nhau trong một sequence được mô tả/khớp bằng các modality khác nhau thay vì bắt toàn bộ chuỗi dùng chung một modality. Đây rất sát với cải tiến tôi đề xuất cho TRAKE. ¹³

Nhóm temporal grounding mới giúp xử lý “<10 frames”

MomentMix + Length-Aware DETR, WACV 2026, xuất phát trực tiếp từ quan sát rằng các model moment retrieval gặp khó với **short moments**, đặc biệt trong việc dự đoán đúng center và duration; model cải thiện rõ các metric cho short-event localization. Đây là nghiên cứu nên đọc nếu bạn định train/fine-tune một temporal localization head thay vì chỉ dùng cosine. ¹⁴

HieraMamba, CVPR 2026, nhấn mạnh đúng tension của AIC: video dài đòi global context nhưng downsample quá mạnh lại làm mất fine temporal detail. Kiến trúc hierarchical của họ được thiết kế để giữ cả hai. ¹⁵

ResidualViT, ICCV 2025, cũng rất thực dụng cho hệ thống thi: nhiều temporal grounding task cần dense frame-level features nhưng encode mọi frame quá tốn tài nguyên; phương pháp khai thác redundancy giữa frame liên tiếp để giảm chi phí dense encoding. ¹⁶

Hai preprint rất mới tháng 7/2026 cũng đáng theo dõi. **TimeLens2** mô hình hóa temporal evidence thành một tập interval có số lượng biến đổi thay vì chỉ một span cố định; **TimePLE** chuyển từ dự đoán hai endpoint độc lập sang dự đoán interval như một đối tượng thống nhất và báo cáo lợi ích đặc biệt cho short-duration events. Chúng mới hơn và chưa phải lựa chọn đầu tiên để triển khai thi ngay, nhưng rất liên quan về mặt nghiên cứu. ¹⁷

Nhóm dùng LLM/VLM nhưng không nên để LLM thay thế retrieval

ED-VTG rất đáng đọc vì nó gần đúng ý tưởng `LLM → enrich query → grounding` của bạn. Điểm quan trọng là tác giả không tin enrichment một cách mù quáng; họ dùng cơ chế training để lựa chọn representation tốt và giảm ảnh hưởng hallucination. ⁶


TOGA hữu ích cho QA vì jointly generate answer và temporal grounding. ⁴


LensWalk, CVPR 2026, lại hỗ trợ một hướng rất phù hợp với AIC: không cần đọc video với density cố định ngay từ đầu. Model có thể scan thưa ở phạm vi rộng rồi quan sát dày hơn ở vùng nghi ngờ. Đây gần chính xác với chiến lược coarse retrieval → dense refinement mà tôi khuyến nghị. ¹⁸

Tôi **không khuyên** lấy một Video-LLM lớn rồi feed toàn bộ video làm giải pháp chính. Retrieval over hundreds of hours cần index offline và candidate pruning; VLM phù hợp hơn ở **reranking/refinement trên top candidate clips**.

Kiến trúc giải pháp tôi đề xuất

Tôi sẽ xây lại sơ đồ của bạn thành kiến trúc dưới đây.





Offline preprocessing

Đây là phần tôi sẽ ưu tiên nhất trước khi tối ưu model.

Bạn cần một canonical table kiểu:

video_id	keyframe_id	timestamp_sec	original_frame_id	shot_id
L01_V001	0000	1.84	46	0
L01_V001	0001	4.28	107	0
L01_V001	0002	8.92	223	1

Đây phải là single source of truth của cả pipeline.

Không component nào được tự suy luận:

0007.jpg → frame_id = 7

vì đó chỉ là keyframe index.

Sau đó tạo các index sau.

Visual coarse index

BTC CLIP-B/32 feature

là baseline bắt buộc vì đã được cung cấp, rẻ và nhanh.

Nếu GPU/storage cho phép, thêm:

Perception Encoder
hoặc
SigLIP2

như secondary retrieval/reranking space. PE được thiết kế cho image/video understanding và được MERVIN sử dụng; SigLIP2 có multilingual training và cải thiện retrieval/localization. ¹⁹

OCR index

Extract OCR từ:

- BTC objects không thay OCR;
- keyframes;
- nếu cần, thêm frames gần scene boundaries.

AIC 2025 DANTE/QUEST system cho thấy OCR độc lập có thể tìm đúng những query chứa text mà semantic visual search khó xử lý. ¹⁰

ASR index

Tạo transcript segments:

```
{  
  "video": "L01_V001",  
  "start": 120.2,  
  "end": 124.8,  
  "text": "..."  
}
```

sau đó:

- lexical search,
- Vietnamese embedding search.

MERVIN cho thấy transcript là một thành phần trung tâm chứ không phải auxiliary feature. ¹¹

Temporal captions

Không nhất thiết caption mọi frame bằng VLM lớn.

Có thể caption theo shot:

```
shot 17:  
"Người dẫn chương trình đứng trước màn hình trình chiếu..."  
  
shot 18:  
"Một chiếc ô tô màu đỏ tiến vào sân khấu..."
```

Nếu làm tốt hơn, cho captioner một ít context từ shot trước để tránh caption rời rạc; U-CESE/ReCap đi theo hướng temporal-consistent captioning này. ¹²

Query Planner mới

Tôi đề xuất LLM trả JSON schema ổn định:

```
{
  "task": "TRAKE",
  "raw_query": "...",
  "normalized_vi": "...",
  "global_visual_en": "...",
  "entities": [],
  "ocr_terms": [],
  "speech_terms": [],
  "events": [
    {
      "id": 1,
      "visual_en": "...",
      "ocr_terms": [],
      "speech_terms": [],
      "relation_to_next": "before"
    }
  ]
}
```

Một điểm nhỏ nhưng quan trọng: **nếu loại task đã được BTC/API cho biết, đừng để LLM tự đoán task_type**.

Hãy truyền thẳng:

```
task_type = official_query_type
```

Planner chỉ parse nội dung.

Một LLM classification error không đáng để đánh đổi khi thông tin đó đã biết chắc.

Candidate generation

Mỗi branch trả candidate riêng.

Ví dụ:

```
Visual CLIP:
L03_V007@kf42  rank 1
L03_V007@kf43  rank 2
L08_V004@kf20  rank 3
```

OCR:
L03_V007@kf43 rank 1

ASR:
L03_V007@182s rank 2

Caption:
L03_V007@shot19 rank 1

Sau fusion, thay vì chỉ ranking frame, hãy aggregate cả theo **temporal regions/video**.

Các frame lân cận:

kf42, kf43, kf44

không nên chiếm ba vị trí độc lập và khiến một video dominate ranking chỉ vì có nhiều near-duplicate keyframes.

Có thể group theo:

same video + temporal proximity

rồi lấy max/mean/top-m score.

KIS head

Một thiết kế thực tế:

```
Top 1000 coarse keyframes
    ↓
cluster temporal neighbors
    ↓
Top 50-100 candidate intervals
    ↓
dense scan top 10-30 intervals
    ↓
strong rerank
    ↓
diversified Top-100
```

Dense scan không nhất thiết encode hàng triệu frame trước.

Ví dụ:

1. candidate ± 5 s;
2. sample 5 fps;

3. lấy top 2 local peaks;
4. quanh mỗi peak scan every frame ± 0.5 s.

Chi phí giảm cực mạnh so với dense encode toàn bộ corpus.

QA head

Retrieval query của QA nên tách thành:

```
event_retrieval_text
question_for_answering
```

Ví dụ:

“Trong cảnh một người phụ nữ mặc áo xanh đang nói chuyện với phóng viên, trên micro ghi tên kênh truyền hình nào?”

Retrieval text tốt hơn có thể là:

```
woman in blue talking to a reporter holding a microphone
```

còn:

```
what television channel name is written on the microphone?
```

là answer question.

Sau đó:

$$Score(frame) = w_v Visual + w_o OCR + w_a Answer Evidence.$$

Nếu answer phụ thuộc motion:

```
“người đàn ông lấy vật gì ra khỏi túi?”
```

thì một still keyframe rõ ràng là không đủ; dùng clip.

TRAKE head

Giả sử có N event và candidate video v .

Tạo similarity tensor:

$$S_{j,t}^v = w_{vis} s_{j,t}^{vis} + w_{cap} s_{j,t}^{cap} + w_{ocr} s_{j,t}^{ocr} + w_{asr} s_{j,t}^{asr}.$$

Weights có thể query-dependent. Event kiểu:

“màn hình hiện dòng chữ...”

thì:

$$w_{ocr} \uparrow .$$

Event:

“người đàn ông giơ tay...”

thì:

$$w_{vis} \uparrow .$$

Event:

“người dẫn chương trình nói ‘xin chào’...”

thì:

$$w_{asr} \uparrow .$$

Sau đó chạy:

$$DP[j, t] = S[j, t] + \max_{\tau < t} [DP[j - 1, \tau] - \lambda g(t - \tau)].$$

DANTE dùng linear distance penalty và đã chứng minh cách tiếp cận DP narrative ordering khả thi trong chính TRAKE AIC 2025. ¹⁰

Tôi sẽ không khóa $g(x) = x$ trong mọi query.

Có thể:

$$g(x) = \log(1 + x)$$

cho sequence có event cách xa nhau; hoặc penalty nhỏ nếu query không nói các event xảy ra sát nhau.

Sau coarse path:

```
event 1 → 01:20.4  
event 2 → 02:13.1  
event 3 → 02:44.8
```

đừng submit ngay.

Dense refine:

```
event 1: 01:19.0 - 01:22.0 → exact frame
event 2: 02:11.5 - 02:15.0 → exact frame
event 3: 02:43.0 - 02:47.0 → exact frame
```

và đảm bảo:

$$f_1 < f_2 < \dots < f_N.$$

Local evaluator

Phần cuối ảnh của bạn:

```
CSV
↓
local evaluator
↓
R@1/5/20/50/100
↓
diagnose rank/video/event sai
```

là **rất đúng** và tôi sẽ giữ nguyên.

Nhưng evaluator nên trả thêm breakdown:

```
query_id
task
best_R@1
best_R@5
best_R@20
best_R@50
best_R@100

video_hit@1
video_hit@5

TRAKE:
event_1_hit
event_2_hit
...
mean_event_hit

frame_error_to_interval
```

Đặc biệt với TRAKE, nếu video đúng nhưng:

```
event 1: 91%
event 2: 85%
```

```
event 3: 22%
event 4: 88%
```

thì bạn biết vấn đề là model representation/localization của event 3, không phải retrieval video.

Notebook baseline thực sự làm gì và có thay đổi logic xử lý không

Notebook này không phải full baseline của cuộc thi

Ngay phần đầu notebook ghi rõ nó là:

“Hướng dẫn truy vấn dữ liệu thị giác dùng fiftyone”

và mục tiêu là giới thiệu **một phương pháp cơ bản để truy vấn dữ liệu** và công cụ FiftyOne để đánh giá/trực quan kết quả.

Nó không hề implement full:

```
Textual KIS evaluator
Q&A
TRAKE
Top-100 ranking
CSV submission
Final Score
```

Tôi đọc 33 cells và chức năng chính của nó là như sau.

Nó import keyframes vào FiftyOne

Cell:

```
dataset = fo.Dataset.from_images_dir(
    'D:\\AICBaseline\\KeyFrames_L01\\keyframes',
    name=None,
    tags=None,
    recursive=True
)
```

Nghĩa là sample của FiftyOne là **ảnh keyframe**, chưa phải video.

Thậm chí path ví dụ chỉ là:

```
KeyFrames_L01
```

nên bản notebook nguyên gốc cũng chưa tự động ingest toàn bộ dataset.

Nó thêm `video` và `frameid` từ `filepath`

Đây là cell quan trọng nhất cần hiểu:

```
for sample in dataset:
    _, sample['video'], sample['frameid'] = \
        sample['filepath'][:-4].rsplit('\\', 2)
    sample.save()
```

Giả sử:

```
...\\L01_V001\\0042.jpg
```

thì notebook tạo:

```
sample["video"] = "L01_V001"
sample["frameid"] = "0042"
```

`0042` ở đây chỉ là filename stem.

Trong khi tài liệu BTC ghi rất rõ:

Keyframe được đặt tên theo thứ tự tăng dần; vị trí frame index tương ứng của mỗi keyframe được ghi trong metadata.

(Nguồn: Thông tin vòng Sơ tuyển AIC2026.pdf, mục 3.)

Vì vậy rất có thể:

```
0042.jpg
```

có thể tương ứng original:

```
frame 6,731
```

chẳng hạn.

Cho nên:

```
sample["frameid"] trong notebook /
```

Đây là điểm tôi muốn bạn đặc biệt lưu ý.

Notebook đặt tên field là `frameid` hơi dễ gây hiểu nhầm.

Tôi sẽ rename trong code thực tế thành:

```
sample["keyframe_idx"]
```

và thêm riêng:

```
sample["original_frame_id"]  
sample["timestamp_sec"]
```

Cell object detection chỉ phục vụ annotation/search bổ sung

Cell 16 đọc:

```
objects-sample/objects/{video}/{frameid}.json
```

sau đó lọc detection:

```
if scoref > 0.4:
```

và lưu:

```
sample["object_faster_rcnn"]
```

Điều này giúp FiftyOne hiển thị/filter object.

Nhưng **object detections** này không tự động đi vào CLIP similarity score trong Cell 29.

Có nghĩa notebook không làm:

$$score = CLIP + object.$$

Nó chỉ gán detections vào sample.

Muốn object branch ảnh hưởng retrieval, chính bạn phải viết logic như:

```
query → extract object constraints  
→ filter/rerank candidates using detection labels
```

Nó nạp đúng CLIP feature do BTC cung cấp

Notebook thu thập keyframes, sort:

```
video_keyframe_dict[k] = sorted(v)
```

sau đó:

```
a = np.load(clip_path)

for i, k in enumerate(video_keyframe_dict[v]):
    embedding_dict[v][k] = a[i]
```

Điều này dựa đúng vào quy ước BTC:

vectors trong `.npy` tăng dần tương ứng với thứ tự keyframe.

(Nguồn: *Thông tin vòng Sơ tuyển AIC2026.pdf*, mục 3.)

Sau đó notebook ghép embedding vào từng FiftyOne sample:

```
clip_embeddings = []

for sample in dataset:
    clip_embedding = \
        embedding_dict[sample['video']][sample['frameid']]
    clip_embeddings.append(clip_embedding)
```

`compute_similarity()` thực sự làm gì?

Cell:

```
fob.compute_similarity(
    dataset,
    model="clip-vit-base32-torch",
    embeddings=clip_embeddings,
    brain_key="img_sim",
)
```

không re-encode lại toàn bộ images bằng CLIP vì đã truyền:

```
embeddings=clip_embeddings
```

Nó tạo một **similarity index** trên các precomputed vectors đó, đồng thời lưu model `clip-vit-base32-torch` để index có thể hỗ trợ compatible text prompt search. Đây chính là use case được tài liệu FiftyOne hỗ trợ chính thức. ²⁰

Sau đó có thể search đại loại:

```
view = dataset.sort_by_similarity(
    "a man wearing a red shirt speaking outdoors",
    k=100,
    brain_key="img_sim",
)
```

FiftyOne sẽ:

```
text
→ CLIP-B/32 text embedding
→ similarity to provided image embeddings
→ ranked keyframes
```

FiftyOne documentation hiện cũng minh họa trực tiếp text prompt search qua `sort_by_similarity()` trên một index tạo bằng `clip-vit-base32-torch`. ⁷

Vậy notebook có thay đổi logic end-to-end của bạn không?


Không.

Bạn có thể hiểu notebook như một implementation của đúng một block:

CLIP Retrieval Backend + Visualization

trong sơ đồ lớn của bạn.

Tức là:



Bạn cũng có thể thay block đó bằng:

FAISS

hoặc:

Milvus

hoặc đơn giản:

```
scores = text_emb @ image_embs.T
```

mà **algorithmic logic không đổi**.

FiftyOne hỗ trợ nhiều similarity backend, bao gồm sklearn mặc định và các backend như Milvus, Qdrant, Elasticsearch, pgvector... nên bản chất của FiftyOne ở đây là indexing/search/inspection infrastructure chứ không phải một model TRAKE hay QA. ²⁰

Notebook không chứa những gì

Tôi không thấy bất kỳ code nào trong notebook làm:

```
LLM rewrite
LLM planner
10 expansions
MMR
RRF
Q&A VLM
event decomposition
TRAKE DP
dense frame refinement
Top-100 candidate allocation
official local evaluator
CSV submission
```

Do đó sơ đồ của bạn không bị baseline “xung đột logic”.

Thực tế đúng hơn là:

Notebook baseline chỉ cung cấp tầng retrieval cơ bản để bạn xây hệ thống phía trên

Có hai chỗ tôi sẽ không bê nguyên notebook sang production

Thứ nhất là Windows path:

```
'D:\\AICBaseline\\...'
```

và:

```
rsplit('\\', ...)
```

nên code không portable sang Linux server.

Nên dùng:

```
from pathlib import Path

p = Path(sample["filepath"])
video_id = p.parent.name
keyframe_id = p.stem
```

Thứ hai và quan trọng hơn là **frame mapping**.

Production record nên là:

```
{
  "video_id": "L01_V001",
  "keyframe_idx": 42,
  "keyframe_filename": "0042.jpg",
  "original_frame_id": 6731,
  "timestamp_sec": 269.24,
  "embedding": ...
}
```

Không được collapse tất cả thành một field tên `frameid`.

Hướng triển khai tối ưu tiên cho đội của bạn

Nếu mục tiêu là nhanh chóng có một hệ thống mạnh hơn baseline mà chưa đốt quá nhiều GPU, tôi sẽ triển khai theo bốn tầng.

Bản đầu tiên: làm đúng frame trước khi làm model mạnh

Pipeline:

```
Vietnamese query
↓
normalize
↓
raw + literal English + 2-3 structured visual queries
↓
CLIP-B/32 retrieval
↓
```

```

Weighted RRF
  ↓
candidate videos/regions
  ↓
metadata mapping
  ↓
dense raw-video refinement
  ↓
original frame_id

```

TRAKE thêm:

```

event decomposition
→ per-event CLIP similarity
→ DP
→ dense refine

```

Ở bước này chưa cần PE, SigLIP2, VLM lớn.

Tôi cho rằng đây là upgrade có tỷ lệ **hiệu quả/công sức cao nhất**, vì nó trực tiếp sửa mismatch giữa coarse keyframe retrieval và cách BTC chấm frame cực ngắn.

Bản tiếp theo: multimodal retrieval

Thêm:

```

OCR
ASR
shot captions

```

vào index.

Đây là hướng đã được nhiều hệ thống AIC gần đây sử dụng, gồm MERVIN, AIO-Owlgorithms và U-CESE.

3

Fusion:

```

visual_rank
OCR_rank
ASR_rank
caption_rank
↓
weighted RRF

```

Sau đó làm ablation:

Experiment	Visual	OCR	ASR	Caption
A	✓			
B	✓	✓		
C	✓	✓	✓	
D	✓	✓	✓	✓

Đừng chỉ đo Final Score chung. Đo riêng:

Textual KIS
QA
TRAKE-video
TRAKE-event

Bản mạnh hơn: secondary encoder + reranker

Giữ CLIP B/32 vì nó miễn phí và rất nhanh.

Thêm:

Perception Encoder
hoặc
SigLIP2

để rerank khoảng 1,000–5,000 candidates, hoặc tạo parallel index.

PE có nền tảng mạnh về image/video retrieval và đã có AIC-specific precedent thông qua MERVIN; SigLIP2 đáng thử cho query tiếng Việt/multilingual. ²¹

Không nhất thiết encode toàn video bằng VLM hàng tỷ tham số.

Bản cuối: task-specific temporal refinement

Với **KIS**:

coarse hit
→ local dense features
→ frame peak

Với **QA**:

coarse hit
→ evidence clip
→ VLM + OCR + ASR

- answer/support interval
- exact frame

Với **TRAKE**:

- top candidate videos
- multimodal event × time matrix
- K-best DP
- dense per-event refinement
- diversified Top-100


Nếu còn thời gian train temporal grounding head, MomentMix/Length-Aware DETR và HieraMamba là hai nghiên cứu 2026 tối ưu tiên đọc trước do một bên tập trung short moments, một bên tập trung giữ fine temporal structure trong video dài. ²²


Một kiến trúc TRAKE cuối cùng tôi cho là hợp lý nhất

Tôi sẽ dùng:

Global Video Retrieval + Event Coverage + Monotonic Alignment + Dense Frame Refinement

Cụ thể:





Trong toàn bộ quá trình, tôi sẽ xem **CLIP keyframes là retrieval anchors, không phải final temporal labels**.

Đó là thay đổi quan trọng nhất so với sơ đồ hiện tại của bạn.

Và cũng là điểm nối trực tiếp giữa hai phần câu hỏi của bạn: notebook baseline giúp bạn rất tốt ở đoạn:

text → CLIP keyframe retrieval

nhưng **nó không giải quyết phần khó nhất của AIC 2026**:

keyframe retrieval
 → true video moment
 → exact original frame_id
 → ordered multi-event alignment
 → grounded QA
 → metric-aware Top-100 ranking.

Vì BTC xác định **Video là dữ liệu chính thức** còn keyframes/features chỉ là hỗ trợ, tôi sẽ thiết kế mọi component theo nguyên tắc: **retrieval có thể chạy trên dữ liệu tiền xử lý, nhưng quyết định cuối cùng phải quay trở lại video gốc**. (Nguồn: *Thông tin vòng Sơ tuyển AIC2026.pdf*, mục 3.)

1 10 Integrated Semantic and Temporal Alignment for Interactive Video Retrieval
<https://arxiv.org/abs/2512.13169>

2 14 22 WACV 2026 Open Access Repository
https://openaccess.thecvf.com/content/WACV2026/html/Park_MomentMix_Augmentation_with_Length-Aware_DETR_for_Temporally_Robust_Moment_Retrieval_WACV_2026_paper.html?utm_source=chatgpt.com

3 11 MERVIN: A Unified Framework for Multimodal Event Retrieval in Vietnamese News Videos
https://arxiv.org/abs/2605.16120?utm_source=chatgpt.com

- 4 ICCV 2025 Open Access Repository
https://openaccess.thecvf.com/content/ICCV2025/html/Gupta_TOGA_Temporally_Grounded_Open-Ended_Video_QA_with_Weak_Supervision_ICCV_2025_paper.html?utm_source=chatgpt.com
- 5 RAPID: Retrieval-Augmented Parallel Inference Drafting for Text-Based Video Event Retrieval
https://arxiv.org/abs/2501.16303?utm_source=chatgpt.com
- 6 ICCV 2025 Open Access Repository
https://openaccess.thecvf.com/content/ICCV2025/html/Pramanick_Enrich_and_Detect_Video_Temporal_Grounding_with_Multimodal_LLMs_ICCV_2025_paper.html?utm_source=chatgpt.com
- 7 20 FiftyOne Brain — FiftyOne 1.19.0 documentation
https://docs.voxel51.com/brain/index.html?utm_source=chatgpt.com
- 8 SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features
https://arxiv.org/abs/2502.14786?utm_source=chatgpt.com
- 9 15 CVPR 2026 Open Access Repository
https://openaccess.thecvf.com/content/CVPR2026/html/An_HieraMamba_Video_Temporal_Grounding_via_Hierarchical_Anchor-Mamba_Pooling_CVPR_2026_paper.html?utm_source=chatgpt.com
- 12 U-CESE: Unified Clip-based Event Search Engine for AI Challenge HCMC 2025
https://arxiv.org/abs/2605.23274?utm_source=chatgpt.com
- 13 Enhanced Multimodal Video Retrieval System: Integrating Query Expansion and Cross-modal Temporal Event Retrieval
https://arxiv.org/abs/2512.06334?utm_source=chatgpt.com
- 16 ICCV 2025 Open Access Repository
https://openaccess.thecvf.com/content/ICCV2025/html/Soldan_ResidualViT_for_Efficient_Temporally_Dense_Video_Encoding_ICCV_2025_paper.html?utm_source=chatgpt.com
- 17 TimeLens2: Generalist Video Temporal Grounding with Multimodal LLMs
https://arxiv.org/abs/2607.17423?utm_source=chatgpt.com
- 18 CVPR 2026 Open Access Repository
https://openaccess.thecvf.com/content/CVPR2026/html/Li_LensWalk_Agentic_Video_Understanding_by_Planning_How_You_See_in_CVPR_2026_paper.html?utm_source=chatgpt.com
- 19 21 Perception Encoder: The best visual embeddings are not at the output of the network
https://arxiv.org/abs/2504.13181?utm_source=chatgpt.com